

任务一：基于机器学习的文本分类

1. 数据集: [Classify the sentiment of sentences from the Rotten Tomatoes dataset](#)

数据集的划分: kaggle 上该数据集中的 train.tsv :70%作为训练集 30%作为测试集

2.文本特征表示:

Bag of words 空间复杂度 $O(n)$

N_Gram 空间复杂度 $O(n*n)$

3.学习方法:

softmax regression 进行多分类

损失函数 交叉熵

数学方法求最优: 梯度下降 (批量, 小批量, 随机)

4.实验设置:

样本个数: sample=2000


学习率: 0.001~10000

minibatch size:sample/200

训练集: 测试集=7:3


5.实验结果:

epoch=1000, 2-Gram:




可以看到稍大的学习率可以让模型收敛, 小的学习率效果不太好

epoch=10000,2-Gram:




对比上图，可以看到，随着 epoch 的增大，无论是使用 bag of words 还是 Gram，模型在训练集，测试集的效果都在变好，但是 Gram 的效果要优于 bag of words，因为 2_Gram 考虑的两个词之间的顺序以及是否连续

epoch=1000, 3-Gram:



epoch=10000, 3-Gram:



改为 3_Gram 之后模型的提升效果不显著，可能是因为该 train.tsv 的 sentence 都比较短导致的，所以考虑 2 个词的词序可能和考虑 3 个词的词序的效果差不多。

