

任务一：基于机器学习的文本分类

1. 数据集: [Classify the sentiment of sentences from the Rotten Tomatoes dataset](#)

数据集的划分: kaggle 上该数据集中的 train.tsv :70%作为训练集 30%作为测试集

2.文本特征表示:

Bag of words 空间复杂度 $O(n)$

N_Gram 空间复杂度 $O(n*n)$

3.学习方法:

softmax regression 进行多分类

损失函数 交叉熵

数学方法求最优: 梯度下降 (批量, 小批量, 随机)

4.实验设置:

样本个数: sample=2000


学习率: 0.001~10000

minibatch size:sample/200


训练集: 测试集=7:3

5.实验结果:


epoch=1000, 2-Gram:



epoch=10000, 2-Gram:



epoch=1000, 3-Gram:



epoch=10000, 3-Gram:

